

データの可視化

「見る」原則と、騙されないための技術

rkskmt

1

情報可視化とは

2

情報可視化とは？

- データや情報をもつ **関係性** や **特徴** を、視覚的に見て理解できるようにすること
 - 見えないものを **「見える」** 化
 - 人間の **視覚・直感・経験** で共通に扱えるようにする
- 情報視覚化ともいう
 - Information Visualization
 - Data Visualization


💡 なぜ「見る」のか

- 数字の表を眺めても気づけないパターン（外れ値、相関、周期性、クラスタ）が見える
- **図示は最強の前処理**

3

この授業のゴール

- あるWikipediaページの **2025年・1年分の閲覧数** を可視化




① ノート

- ほぼ平坦なのに **1日だけ大きな山**（最大47,656回、ふだんの約300倍）
- この日、何があった？



可視化の古典：ジョン・スノウのコレラ地図

- 1854年、ロンドンで原因不明の病気が大流行
 - 医師 **John Snow** が原因調査をおこなう
 - 感染データを **地図にプロット** したところ Broad Street の井戸の周囲に感染者が集中していることを発見
 - 「水が感染源」という **仮説を視覚で立証**
 - **疫学** という分野の出発点とされる



5

数的グラフの始祖：ウィリアム・プレイフェア


- **William Playfair** (1759-1823) はスコットランドの技師・経済学者
- 現代の **棒グラフ・折れ線グラフ・円グラフ** を **すべて発明**
 - 1786年：*Commercial and Political Atlas* で折れ線・棒グラフを初めて使用
 - 1801年：*Statistical Breviary* で円グラフ（パイチャート）を発明

i スノウとプレイフェア

- **スノウ** — 視覚化で **因果関係を発見** し、社会を変えた
- **プレイフェア** — 視覚化の **形式そのもの** を発明した

6


プレイフェアの折れ線グラフ (1786)



イングランドの国家債務の推移

- 時間を横軸、量を縦軸にとる — 現代の時系列グラフの原型


プレイフェアの棒グラフ（1786）



スコットランドの輸出入 (1780-1781)

- カテゴリ（貿易相手国）を並べて **長さで比較** — 棒グラフの誕生

プレイフェアの円グラフ（1801）



トルコ帝国の領土配分

- 全体に対する **割合を角度で表現** — 円グラフの誕生

9

プレイフェアの問い：なぜ数字を図にするのか

Making information available, for thought and memory, without the **trouble of studying** rows of figures.

—— William Playfair, *Commercial and Political Atlas* (1786)

- 数字の羅列を眺める **苦労を省く** ためにグラフを描く
→ 200年以上前に「視覚化の本質」を言い当てていた

① 可視化の本質

「データに **適切な空間（軸）** を与えること」

10

現代の可視化実例

ジャンル	サンプル
人口動態	Population Pyramids of the World
未来予測ゲーム	INED “Tomorrow’s Population”
気候変動	#ShowYourStripes
統計バブル	Gapminder “Wealth & Health of Nations”
ネットワーク	Force-Directed Graph
地理 + 時系列	earth :: 地球の風・気象
3D点群	Cesium “3D Tiles Point”

💡 ミニアクティビティ

- どれか1つ開いて、**隣の人に30秒で説明** する
 - 何のデータ？ 軸は何？ 何が見えた？
- 動的なものほど **データ量と表現力の関係** がよく分かる

データを扱う際の大原則

“Always plot your data first.”




あらゆるデータは、まず最初に「見て」みる

- 平均や分散などの **統計量だけでは騙される**
- 図にしてはじめて気づける構造がある
- データ分析の最初の一手は **常にプロット**

クイズ：「平均所得 524万円」

- 厚生労働省の調査：日本の1世帯当たり **平均所得は 524万2千円**（2022年）
- では、**所得が平均以下** の世帯は全体のどれくらい？
 - 「平均」なんだから、だいたい半分（50%）……？

平均以下の世帯は 62.2%



- **平均以下の世帯は 62.2%** — 「平均」は真ん中ではない
- 真ん中の値（**中央値**）は **405万円**。平均より **119万円** も低い
→ 一部の高所得世帯が、平均を **右に引っ張る**
- 分布を **見ないと**、「平均」という言葉の意味すら誤解する

ⓘ 出典

厚生労働省「2023（令和5）年 国民生活基礎調査の概況」図9

例：アンスコムの四重奏

- **F. J. Anscombe（1973）** が作った **4つのデータセット**
- 4つとも、以下の統計量が **ほぼ完全に一致** する

統計量	値
x の平均	9 （完全に一致）
x の標本分散	11 （完全に一致）
y の平均	7.50 （小数第2位まで一致）
y の標本分散	4.122 or 4.127 （小数第3位まで一致）
x と y の相関係数	0.816 （小数第3位まで一致）
回帰直線	$y = 3.00 + 0.500x$ （小数第2～3位まで一致）


ⓘ 問題：散布図にしたら、どんな形？

- 統計量がここまで揃っているなら、**4つとも似た形になるはず...だよね？**
- めくる前に **予想して手で描いてみる**

アンスコムの四重奏：普通のデータ

- ばらつきはあるが **ゆるやかに直線的に増える**
- 線形回帰の前提（直線関係 + 均一なばらつき）が成立
- 典型的な普通のデータ

▶ コードを見る




💡 教訓

- 回帰直線が **データの要約として正しく機能**
- 4つの中で線形モデルが成立する **唯一の例**

アンスコムの四重奏：曲線にフィッティング

- **y** が **滑らかな曲線**（2次関数的）を描いている
- 直線を当てはめても本質を捉えられない
- 統計量だけ見ていると「直線で説明できた」と思い込みやすい

▶ コードを見る




⚠ 教訓

- そもそも **直線で表現すべきでない** データ
- 多項式回帰や対数変換などモデルを変える必要あり
- 統計量だけだと **モデル選択ミス** に気づけない

アンスコムの四重奏：外れ値が目立つデータ

- ほぼ **完全な直線** に並んでいる
- たった1点だけ大きく外れている
- その1点に **回帰直線が引っ張られている**

▶ コードを見る




⚠ 教訓

- **外れ値 (outlier)** に統計量が支配される
- 入力ミスとして除外するか、本物の現象として尊重するか
- **図を見ないと判断できない**

アンスコムの四重奏：共通した値を共有したデータ

- x の値が **ほぼすべて 8**
- 1点だけ $x=19$ にあり、その1点が「直線がある」ように見せている
- 同じ条件で測定しすぎていて、 x が振れていない


▶ コードを見る



⚠ 教訓

- サンプルングが偏っている
- 1点だけで「相関がある」と言っているのと同じ
- **実験計画（データの取り方）そのもの** を疑うべきケース

四重奏を並べると...



データ	見た目	何が問題か
① 素直	緩やかな散布 + 直線	線形回帰がうまく機能
② 曲線	2次関数的	モデル選択が間違い
③ 外れ値	直線 + 1個ハズレ	外れ値が統計量を支配
④ x偏り	ほぼ全部同じ x	サンプリングが偏っている

- 統計量は4つとも同じ
- 図にしないと 絶対に気づけない

① だからデータ処理＝まず視覚化


見ればわかる。見なければ見逃す。

現代版アンスコム：Datasaurus Dozen


- **Matejka & Fitzmaurice (2017)** が作った **13個** のデータセット
- どれも以下の統計量が一致（小数第2位まで）

統計量	13個すべてで
x の平均	54.26
y の平均	47.83
x の標準偏差	16.76
y の標準偏差	26.93
相関係数	−0.06

そのうちの1つを散布図にすると...



Datasaurus Dozen : 全13個



- 13個全部、 **同じ平均・同じ標準偏差・同じ相関係数**
- 教訓はアンスコムと同じ — ただし **より強烈に**
- 出典： **Same Stats, Different Graphs (Autodesk Research)** [🔗](#)

💡 作り方も面白い


- 恐竜の形を保ったまま、統計量が変わらないように点を少しずつ動かして生成
- 「統計量は強い要約だが、 **形の情報はほぼ捨てている**」 ことの証明

グラフはウソをつく

ここまでは「正直なグラフ」の話

- アンスコムの教訓： **描かないと、騙される**
- もう一つの現実： **描き方しだいで、人を騙せる**
 - ➔ ニュース・広告・プレゼンで毎日使われているテクニック
- ここからは **騙されない** 練習


商品BはAより圧倒的に売れている？



- 商品Bの圧勝に見える

26

トリック：y軸の切断




⚠ 棒グラフは「長さ」で比較するグラフ

- 実際の差は **約2%**。軸を切ると何倍にも見える
- 棒グラフは **0から描く** のが原則
- 軸の数字を確認するクセをつける

27


東京は寒冷化している？



- 気象庁の実測データ
- 12年間で気温は下降トレンド

28

トリック：期間のチェリーピック



⚠ データが本物でも、切り取りでウソがつける

- 150年で見れば気温は **約4°C上昇**（都市化の影響も大きい）
- 揺らぎのある時系列は、**都合のいい12年** を選べば逆向きに見せられる
- 「**どの範囲を見せるか**」も作為のうち — 全体を確認するクセをつける

29

探索的データ解析（EDA）

- **テューキー（Tukey）** が1977年の著書 **E**xploratory **D**ata **A**nalysis で提唱
 - 「まずデータを **見て** から仮説を立てる」という原則
 - 統計学の前段として現在も基本中の基本
- 箱ひげ図・幹葉図など、Tukeyが広めた可視化手法は多数

i Tukey

“**bit**”（**bi**nary **di**git の短縮形）や “**software**” の生みの親

30

グラフの種類

- まずは簡単なグラフやプロットでよい
- 目的に応じて使い分ける

種類	用途
散布図	2変量の相関
折れ線	時系列・連続データ
棒グラフ	カテゴリ比較
ヒストグラム	分布把握
3D散布図	3変量関係（回せる Plotly 回 で扱う）

31

まとめ

- **可視化の歴史**：
 - プレイフェア — 棒・折れ線・円グラフを発明
 - スノウ — コレラ地図で因果関係を視覚的に立証
- **大原則**：*Always plot your data first.*
 - 平均所得524万円 ≠ 真ん中（中央値405万円）
 - アンスコム・Datasaurus — 統計量は形を捨てている
- **グラフはウソをつく**：y軸切断・期間チェリーピック — 騙されない側になる
- **冒頭の謎**（1日だけの大きな山）の正体は、**APIデータを可視化する** [🔗](#)で明かされる

32

次回予告

- 今日は「見る」「見抜く」 — **読む側** の話だけだった
- 次回は **描く側** へ：**matplotlib** を使う
 - クイズに出た **東京の気温** を、自分の手で描いて確かめる
 - 1枚のグラフを「資料に載せられるレベル」まで **育てる**

33

参考リンク

- **Anscombe's quartet (Wikipedia)** [↗](#)
- **Same Stats, Different Graphs — Datasaurus Dozen (Autodesk Research)** [↗](#)
- **厚生労働省「国民生活基礎調査」** [↗](#)
- **気象庁「過去の気象データ検索」** [↗](#)

34